Mathematik 2

Statistik

Prof. Dr. Sarah Detzler
sarah.detzler@dhbw-mannheim.de

Wintersemester 2024

Kapitel 1

Statistik

Literatur (jeweils neueste Auflage):

1. Bleymüller, J./Weißbach, R./Dörre, A., Statistik für Wirtschaftswissenschaftler, München
2. Schulze, P. M./Porath, D., Statistik mit Datenanalyse und ökonometrischen Grundlagen, München
3. Schulze, P. M./Porath, D., übungen zur Statistik, München
4. Rößler, I./Ungerer, A., Statistik für Wirtschaftswissenschaftler: Eine anwendungsorientierte Darstellung, Berlin
5. Bamberg, G./Baur, F./Krapp, M., Statistik: Eine Einführung für Wirtschafts- und Sozialwissenschaftler, Berlin/Boston.

1.1 Grundlagen und Grundbegriffe

Was ist Statistik?

1. umgangssprachlicher Gebrauch des Begriffes: quantitative Informationen über bestimmte Tatbestände
2. wissenschaftlicher Gebrauch des Begriffes: Methoden der Erhebung, Aufbereitung und Analyse

von Daten in der Statistik selbst Unterscheidung von **zwei Teilbereichen**:

1. **Deskriptive (Beschreibende) Statistik:**Darstellung von Daten für eine Grundgesamtheit in Tabellen und Schaubildern sowie die Berechnung von Maßzahlen
2. **Wahrscheinlichkeitsrechnung und Induktive (Schließende) Statistik:** häufig keine Vollerhebung möglich, so dass Rückschluss von Stichprobe auf Grundgesamtheit über Wahrscheinlichkeiten nötig;→ Stichprobentheorie, Schätztheorie und Testtheorie

Vorgehensweise bei statistischen Untersuchungen:

1. **Planung/Problemformulierung:** Was will ich eigentlich untersuchen (konkrete Fragestellung)?

2. **Datenerhebung:** Primärstatistik oder Sekundärstatistik (bereits vorhandene Daten)

3. **Datenaufbereitung:** Verdichtung des Datenmaterials (Tabellen und Schaubilder)

4. **Datenanalyse:** Ermittlung von Maßzahlen und Kennziffern

5. **Interpretation:** Was bedeuten meine Ergebnisse vor dem Hintergrund der festgelegten Fragestellung?

Träger der Wirtschaftsstatistik:

1. **amtliche Statistik:** Statistisches Bundesamt (www.destatis.de), Statistische Landesämter, Städtestatistische ämter, Ministerien, Bundesbank, Bundesagentur für Arbeit, Eurostat, EZB, UN, OECD

2. **nichtamtliche Statistik:** Wirtschaftsverbände, Industrie- und Handelskammern, Forschungsinstitute, Großunternehmen

Grundbegriffe der Datenerhebung und Datenanalyse:
Statistische Einheit/Merkmalsträger: Objekt, dessen Eigenschaften festgestellt werden sollen
Statistische Masse/Grundgesamtheit: Gesamtheit der Merkmalsträger
Stichprobe/Teilgesamtheit: Teil der Grundgesamtheit; aus erhebungstechnischen Gründen oft nur Teilbefragungen
Merkmal: bestimmte messbare Eigenschaft eines Merkmalsträgers
Merkmalsausprägung Wert eines Merkmals
Qualitative Merkmale: nur kategoriale Merkmalsausprägung. Sie unterscheiden sich nur durch ihre Art und Weise (z. B. Geschlecht, Nationalität, ...)
Quantitative Merkmale: sinnvolle Zuordnung reeller Zahlen möglich. Sie unterscheiden sich durch ihre Größe, es wird gezählt oder gemessen. (z.B. Alter, Körpergröße, Einkommen, Umsatz,...)
Stetige Merkmale können jeden beliebigen Wert annehmen (z.B. beliebig exakt messbare Größen)
Diskrete Merkmale haben endlich viele Ausprägungen oder auf der Achse mit Ausprägungen Lücken (z. B. Alter in Jahren)
Quasi-stetige Merkmale: sind eigentlich diskret, werden aber als stetig aufgefasst (z. B. Geldbeträge wie Umsatz oder Einkommen)
Nominalskala: Unterschiede feststellbar, aber keine Rangordnung, (z.B. Geschlecht, Nationalität,...)
Ordinalskala: Verschiedenartigkeit und Rangordnung feststellbar, aber Abstände nicht vernünftig quantifizierbar oder interpretierbar, (z. B. Güteklassen, Leistungsklassen, Noten, Ratings,...)
Kardinalskala/metrische Skala: zusätzlich noch sinnvolle(r) Messung/Vergleich der Abstände; Unterscheidung **Intervallskala** (willkürlicher Nullpunkt) und **Verhältnisskala** (absoluter Nullpunkt) (z. B. Alter, Größe, Geldbeträge,...)

Kapitel 2

Deskriptive Statistik bei eindimensionalem Datenmaterial

2.1 Häufigkeitsverteilungen und graphische Darstellung

Häufig liegt das Datenmaterial nach seiner Erfassung in sehr unübersichtlicher Form vor. Der erste Schritt zur Analyse ist die Aufbereitung in tabellarischer Form bzw. mit Hilfe von grafischen Darstellungen.
Hierzu ist es oft sinnvoll un erforderlich die Daten zunächst zu sortieren und (vor allem bei sehr vielen unterschiedlichen Merkmalsausprägungen) zu klassieren, d.h in eignete Klassen einzuteilen.
Klassierungsregeln:

- Vellemann: $2\sqrt(N)$
- Dixon/Kronmal: $10log_{10}(N)$
- Sturges: $1 + 3,3219 \cdot log_{10}(N)$
- Vielfach ist „persönliches“ Augenmaß gefragt!

Wenn Merkmale mindestens ordinal skaliert sind, ergänzt man in der Häufigkeitstabelle noch die kumulierten Häufigkeiten. Im folgenden sei N unsere Daten- bzw. Stichprobengröße, k die Anzahl der mögliche Merkmalsausprägungen und f_i die absolute Häufigkeit der Merkmalsausprägung i so ist die **relative Häufigkeit :**

$$p_i = \frac{f_i}{N} \quad \text{bzw.} \quad p_i = \frac{f_i}{\sum_{j=1}^{k} f_j} \quad \text{mit} \quad \sum_{j=1}^{k} p_j = 1$$

empirische Verteilungsfunktion (nur sinnvoll, wenn mindestens ordinales Skalenniveau vorliegt):

$$F_i = \sum_{j=1}^{i} p_j$$

normierte relative Häufigkeit (bei unterschiedlicher Klassenbreite c_i):

$$p_i^\star = \frac{p_i}{c_i}$$

Je nach **Skalierung der Merkmale** sind unterschiedliche tabellarische und grafische Darstellungen möglich. **Beispiel zu den Häufigkeitsverteilungen:** Befragung in einem Betrieb mit 200 Beschäftigten nach

1. Art der Tätigkeit

Tätigkeitsbereich	f_i	p_i
Vertrieb	10	0,05
Produktion	136	0,68
Verwaltung	54	0,27

Die grafische Darstellung erfolgt über Kreisdiagramm, Säulendiagramm oder Balkendiagramm. Die Zahlenbeschriftung kann mit den absoluten Werten oder Prozentzahlen erfolgen (oder beides)

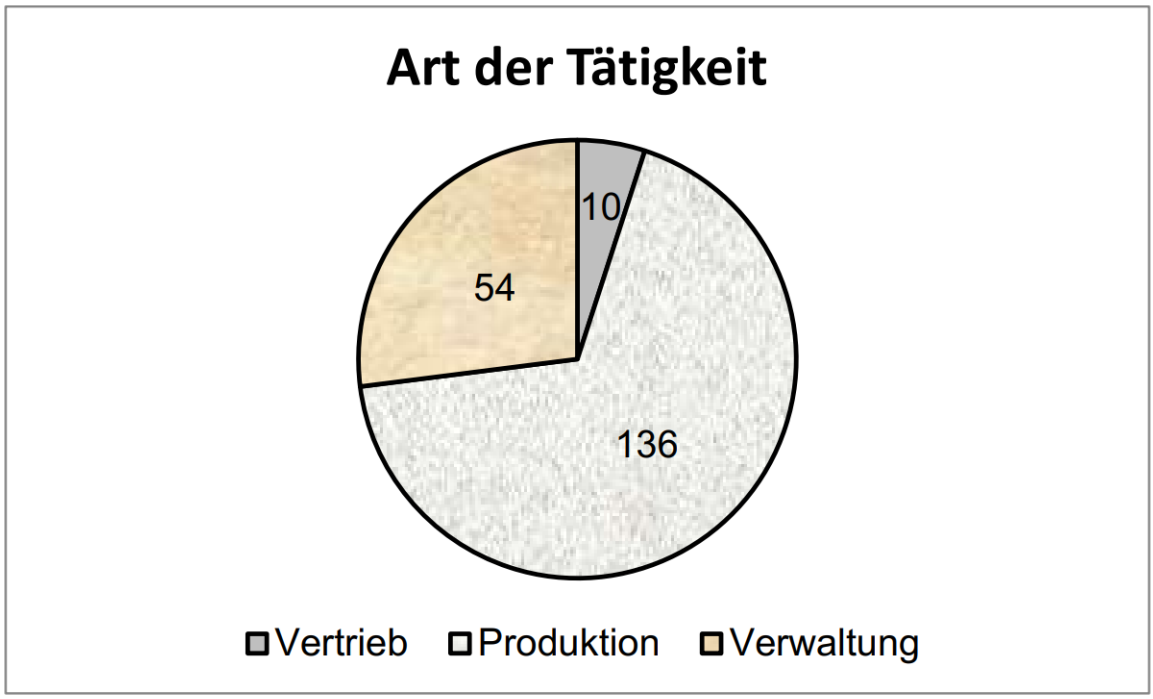

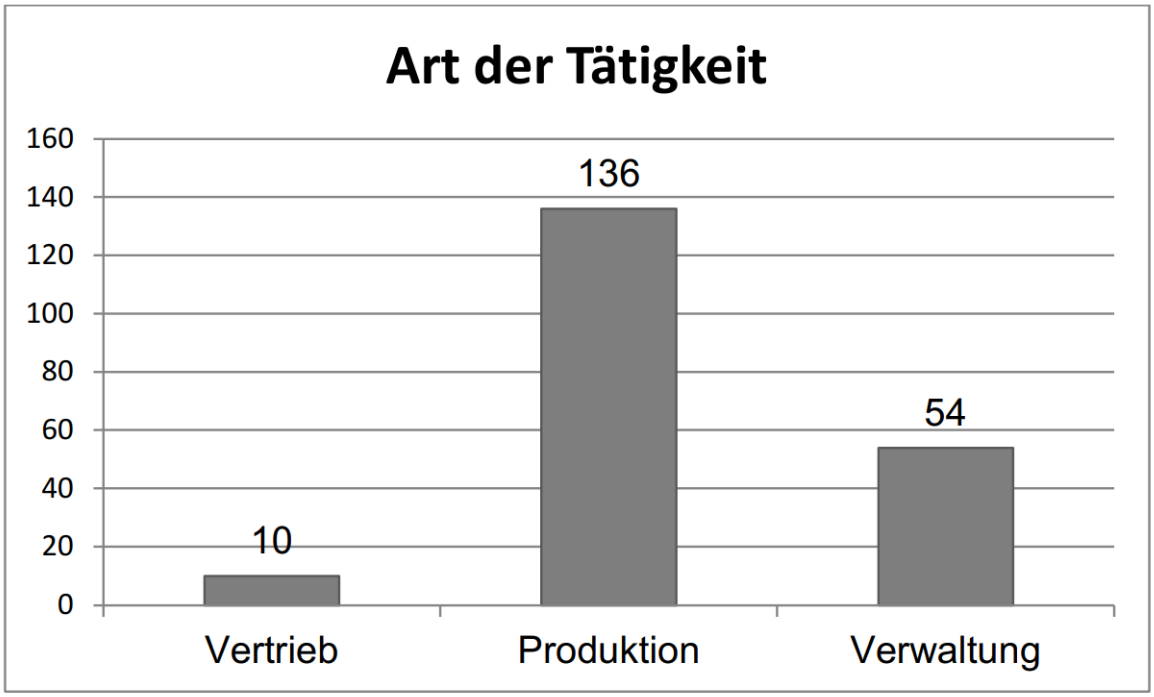

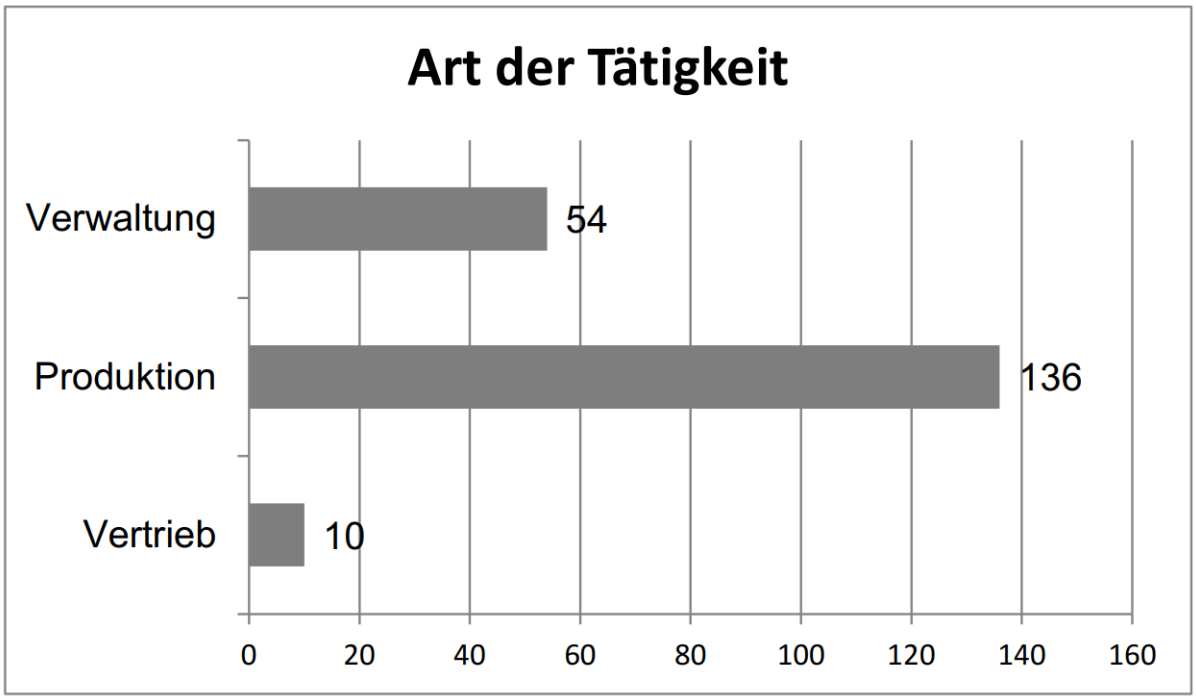

2. Beurteilung der Güte der Sozialleistungen

Bewertung	f_i	p_i	F_i
sehr gut	30	0,15	0,15
gut	90	0,45	0,60
befriedigend	60	0,30	0,90
ausreichend	20	0,10	1,00
schlecht	0	0,00	1,00

Die grafische Darstellung erfolgt über SÄulendiagramm oder Balkendiagramm. Die Zahlenbeschriftung kann mit den absoluten Werten oder Prozentzahlen erfolgen (oder beides):

3. Beurteilung der Güte der Sozialleistungen

Bewertung	f_i	p_i	F_i
sehr gut	30	0,15	0,15
gut	90	0,45	0,60
befriedigend	60	0,30	0,90
ausreichend	20	0,10	1,00
schlecht	0	0,00	1,00

4. Haushaltsgröße

Zahl der Personen	f_i	p_i	F_i
1	48	0,24	0,24
2	60	0,30	0,54
3	44	0,22	0,76
4	32	0,16	0,92
5	14	0,07	0,99
6	2	0,01	1,00

Die **Verteilungsfunktion** wird meist über eine Treppenfunktion grafisch dargestellt (auch schon bei ordinalem Skalenniveau), um zu verdeutlichen, dass nur bestimmte Werte zulässig sind.

5. Nettostundenverdienste

Verdienst	f_i	p_i	F_i	Klassenmitte
7,5 b.u. 12,5	10	0,05	0,05	10
12,5 b.u. 17,5	20	0,10	0,15	15
17,5 b.u. 22,5	24	0,12	0,27	20
22,5 b.u. 27,5	36	0,18	0,45	25
27,5 b.u. 32,5	40	0,20	0,65	30
32,5 b.u. 37,5	60	0,30	0,95	35
37,5 b.u. 42,5	10	0,05	1,00	40

Für eine sinnvolle Darstellung ist eine **Klassenbildung** (Orientierung an Formel von Sturges, aber auch wie hier pragmatisch möglich) notwendig. Im Idealfall sind die Klassen gleich breit und alle Klassen sind geschlossen. Bei stetigen Daten wird die **Verteilungsfunktion** nicht als Treppenfunktion, sondern als durchgezogener Streckenzug dargestellt.

2.2 Lageparameter

Die Beobachtungswerte einer statistischen Masse sollen nun über **Maßzahlen** beschrieben werden. Dabei ist zwischen Lageparametern, Streuungsparametern, Schiefe- und Wölbungsmaßen sowie Konzentrationsmaßen zu unterscheiden.
Die **wichtigsten Lageparameter** sind das arithmetische Mittel (= Mittelwert = Durchschnitt), das geometrische Mittel (für Wachstumsraten), der Zentralwert (= Median) und der Modus (= häufigster Wert). Weitere Lageparameter sind Quartile, Dezile und Perzentile sowie das harmonische Mittel(für Durchschnittsgeschwindigkeiten).
Das **arithmetische Mittel** $\overline{X}$ oder μ der Daten $x_1, \ldots, x_N$ ist nur für kardinal skalierte Merkmale zu berechnen. Je nachdem, ob es sich um einfache Zahlenreihen oder um gruppiertes Datenmaterial handelt, sind unterschiedliche Formeln anzuwenden:
(einfaches) arithmetisches Mittel:

$$\overline{X} = \mu = \frac{1}{N} \sum_i x_i$$

gewogenes arithmetisches Mittel:

$$\overline{X} = \mu = \frac{1}{N} \sum_i x_i^\star \cdot f_i = \sum_i x_i^\star \cdot p_i$$

Das gewogene arithmetische Mittel führt in aller Regel zu einem Informationsverlust, da es über die Klassenmitten $x_i^\star$ berechnet wird. Bei **Veränderungsraten** (z.B. Umsatzwachstum) führt die Anwendung des arithmetischen Mittels zu falschen Ergebnissen. Hier muss das **geometrische Mittel** angewendet werden:
geometrisches Mittel:

$$\overline{G} = \sqrt[N]{\prod_{i=1}^{N} q_i} \text{ mit } q_i = 1 + \frac{\text{relative Änderung in \%}}{100}$$

Ein wichtiger Lageparameter, der schon ab ordinaler Skalierung angewendet werden darf, ist der **Zentralwert (= Median)** Z. Er teilt die Daten in zwei gleiche Hälften:
Zentralwert bei ungruppiertem Datenmaterial:

$$\begin{aligned} Z &= x_{\frac{N+1}{2}} && \text{für } N \text{ungerade} \\ Z &= \tfrac{1}{2}\left(x_{\frac{N}{2}} + x_{\frac{N+2}{2}}\right) && \text{für } N \text{gerade} \end{aligned}$$

Zentralwert bei gruppiertem Datenmaterial: Bei einem klassierten Merkmal liegt der Median genau in der Klasse x_Z, in der die Summenhäufigkeitsfunktion den Wert 0.5 erreicht, bzw. das erste Mal überschreitet. Bei quantitativ-diskreten Merkmalen ergibt sich somit:
$Z =$ Klasse, in der F_i den Wert $0,5$ erreicht
Bei quantitativ-stetigen Merkmalen ergibt sich:

$$Z = x_Z^{min} + c_Z \cdot \frac{0,5 - F_{Z-1}}{p_Z}$$

wobei x_Z^{min} Untere Klassengrenze und die Breite c_Z der Klasse ist.
Die Idee des Medians lässt sich verallgemeinern:

- Der Median teilt den Datensatz in zwei Hälften, die jeweils 50% der Daten umfassen.
- Nun: Suche Wert, der Datensatz in beliebige Anteile teilt, etwa im Verhältnis 90% zu 10%. Gezählt wird immer der Anteil, der vor dem Quantil liegt, dieser wird als Index notiert:
- Q_p ist derjenige Wert, den der Anteil p der Daten nicht überschreitet und der Anteil $(1-p)$ der Daten nicht unterschreitet.

$$\begin{aligned} Q_p &= x_{\lceil N \cdot p \rceil} && \text{für } Np \notin \mathbb{N} \\ Q_p &= \tfrac{1}{2}\left(x_{N \cdot p} + x_{N \cdot p+1}\right) && \text{für } Np \in \mathbb{N} \end{aligned}$$

wobei $\lceil Np \rceil$ heißt, das auf die nächst höhere ganze Zahl aufgerundet wird.
Quantil (klassierte Daten):

$$Q_p = x_i^{min} + c_i \cdot \frac{p - F_{i-1}}{p_Z}$$

wobei x_i die erste Klasse ist in der $F_i \geq p$.
Bei jedem Skalenniveau ist der **Modus** ermittelbar. Dies ist derjenige Wert, der am häufigsten auftritt. Liegen Klassen mit quantitativ-stetigen Merkmalen vor, erfolgt eine Feinberechnung des Modus:

$$M = x_M^{min} + c_M \frac{\Delta 1}{\Delta 1 + \Delta 2} \text{ mit } (\Delta 1 = p_M - p_{M-1},\ \Delta 2 = p_M - p_{M+1})$$

wobei x_M die Häufigste Klasse ist, x_M^{min} ihre untere Klassengrenze und ihre Breite c_M. Bei unterschiedlichen Klassenbreiten sind die relativen Häufigkeiten zu **normieren**. Diese erhält man durch

$$p_i^\star = \frac{p_i}{c_i}$$

Bei statistischen Analysen hängt es vom **Skalenniveau** sowie der **konkreten Fragestellung** ab, welcher Lageparameter tatsächlich berechnet werden soll. Dabei ist auch die unterschiedliche Anfälligkeit gegenüber **Ausreißern** zu berücksichtigen. Mit der gängigen Statistiksoftware, wie z.B. SPSS, ist eine einfache Berechnung aller Parameter möglich. Dies ermöglicht zudem erste Aussagen über die **Schiefe** einer Verteilung nach der Fechnerschen Lageregel.
Fechnersche Lageregel:
$\overline{X} < Z < M$ rechtssteile=linksschiefe Verteilung
$\overline{X} > Z > M$ linkssteile=rechtsschiefe Verteilung
$\overline{X} = Z = M$ symmetrische Verteilung

2.3 Streuungsparameter

Während die Lageparameter in erster Linie eine Aussage über das Verteilungszentrum treffen, stellen Streuungsparameter Aussagen über Abweichungen bereit. Die **wichtigsten Streuungsparameter** sind die Spannweite, die Standardabweichung (= Wurzel aus der Varianz)

und der Variationskoeffizient (= relative Streuung). Geringere Bedeutung haben dagegen der Quartilsabstand und die mittlere absolute Abweichung. Für ordinal und kardinal skalierte Merkmale kann die **Spannweite** berechnet werden:

$$R = x_{i(max)} - x_{i(min)}$$

Beim Vorliegen von Klassen verwendet man die obere Klassengrenze der obersten Klasse und die untere Klassengrenze der untersten Klasse. Für kardinal skalierte Merkmale gibt es eine Reihe von weiteren Streuungsparametern. Wenig gebräuchlich, aber sehr gut interpretierbar ist die **mittlere absolute Abweichung**:

$$MAD = \frac{1}{N} \sum_{i=1}^{N} |x_i - \overline{X}|$$

Von großer Bedeutung sind dagegen die **Varianz** und die aus ihr berechnete **Standardabweichung: Varianz für ungruppierte Daten:**

$$S^2 = \sigma^2 = \frac{1}{N} \sum_{i=1}^{N} (x_i - \overline{X})^2 = \frac{\sum_{i=1}^{N} x_i^2}{N} - \overline{X}^2$$

Varianz für gruppierte Daten:

$$S^2 = \sigma^2 = \frac{1}{N} \sum_{i=1}^{N} f_i \cdot (x_i^\star - \overline{X})^2 = \frac{\sum_{i=1}^{N} f_i \cdot x_i^{\star 2}}{N} - \overline{X}^2$$

Standardabweichung:

$$S = \sigma = \sqrt{S^2}$$

Betrachtet man zwei Verteilungen mit der gleichen Standardabweichung, so ist diese unterschiedlich zu beurteilen, je nachdem in welcher Größenordnung sich das Zahlenmaterial bewegt. Dies berücksichtigt der **Variationskoeffizient (= relative Streuung):**

$$V = \frac{S}{\overline{X}} = \frac{\sigma}{\mu}$$

2.4 Konzentrationsmaße

Bei ökonomischen Anwendungen spielen häufig Konzentrationsmaße eine wichtige Rolle. **Absolute Konzentrationsmaße** sind die Konzentrationsraten CR_x und der Herfindahlindex H, die beide für die **Wettbewerbspolitik** eine große Rolle spielen. Bei den **Konzentrationsraten** werden die Marktanteile der x größten Anbieter addiert:

$$CR_3 = \text{Summe der Marktanteile der 3 größten Anbieter}$$

Den **Herfindahlindex** berechnet man, indem man die quadrierten Marktanteile aller Anbieter aufsummiert:

$$H = \sum (Marktanteil_i)^2 \text{ mit } 0 < H \leq 10.000$$

Die **relative Konzentration** für **verteilungspolitische Fragen** wird mit der Lorenzkurve grafisch beschrieben und mit dem Gini-Koeffizienten G berechnet.
Bei der **Lorenzkurve** werden die Merkmalsträger in aufsteigender Reihenfolge geordnet. Sie stellt dar, welche Anteile der gesamten Merkmalssumme auf welche Anteile der Grundmenge mit N Merkmalsträgern entfallen. So werden auf der x-Achse die Anteile an der Gesamtheit der Merkmalsträger F_i (zum Beispiel Bevölkerung), auf der y-Achse die Anteile an der gesamten Merkmalssumme H_i (beispielsweise Einkommen) abgetragen. Zunächst werden die Daten dafür aufsteigend sortiert - beginnend mit dem geringsten Anteil an der Merkmalssumme - und dann kumuliert (summiert). Dadurch entsteht der charakteristische „Bauch“ der Lorenz-Kurve unterhalb der Diagonalen, welcher das Maß der Ungleichverteilung wiedergibt. Jeder Punkt auf der Lorenz-Kurve steht für eine Aussage wie „die unteren 20 % aller Haushalte beziehen 10 % des Gesamteinkommen„ Eine perfekte Einkommensgleichverteilung wäre eine Einkommensverteilung, bei der alle Personen das gleiche Einkommen besitzen. In diesem Falle würden stets die unteren n% der Gesellschaft n % des Einkommens haben. Dies lässt sich anschaulich durch eine Gerade $y = x$ darstellen. Dagegen wäre die perfekte Ungleichverteilung eine Verteilung, bei der eine Person über das gesamte Einkommen verfügt und alle anderen Personen kein Einkommen beziehen.

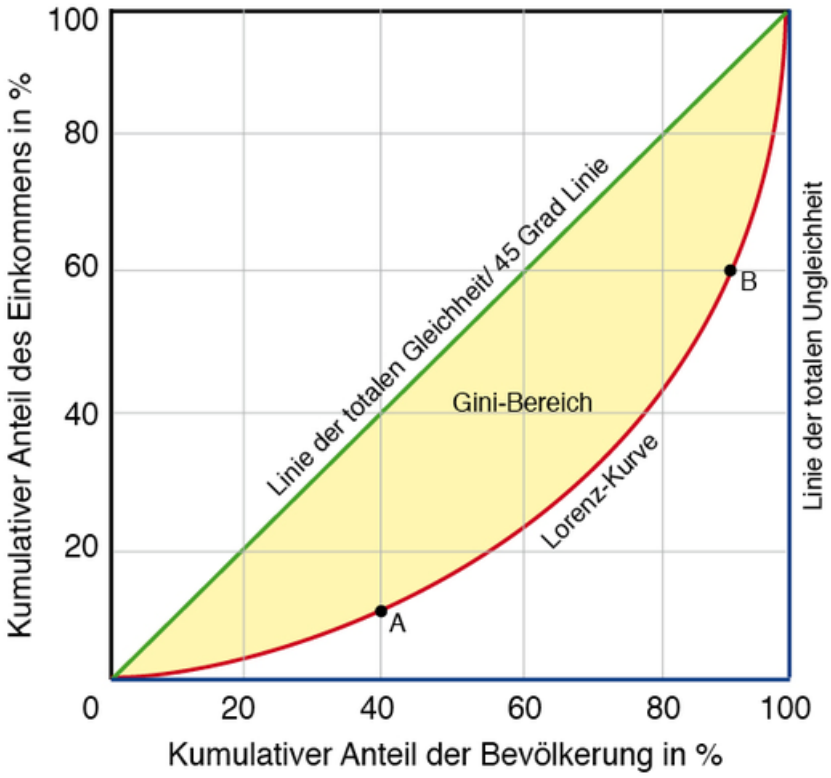

Der Gini-Koeffizient ist der Anteil der Fläche zwischen der perfekten Gleichverteilungsgerade und der beobachteten Lorenz-Kurve an der Fläche unter der Gleichverteilungsgerade. Der Gini-Koeffizient ist damit eine Zahl zwischen 0 und 1, je höher er ist, desto ungleicher ist die Verteilung. Der **Gini-Koeffizient** kann wie folgt berechnet werden:

$$G = \sum_{i=1}^{n-1} F_i \cdot H_{i+1} - \sum_{i=1}^{n-1} F_{i+1} \cdot H_i \text{ mit } 0 \leq G < 1$$

Kapitel 3

Deskriptive Statistik bei mehrdimensionalem Datenmaterial

3.1 Darstellungsweise und Indexzahlen

Liegen **zwei Merkmale** X **und** Y vor, so erfolgt die Darstellung in Kontingenztabellen mit **gemeinsamen absoluten** f_{ij} **oder gemeinsamen relativen Häufigkeiten** p_{ij}**:**

$$p_{ij} = \frac{f_{ij}}{N}$$

Außerdem können folgende Größen berechnet werden:
Randverteilungen:

$$p_{i\bullet} = \sum_{j=1}^{c} p_{ij} = \frac{f_{i\bullet}}{N} \text{ für } j = 1, \ldots, r$$

$$p_{\bullet j} = \sum_{i=1}^{c} p_{ij} = \frac{f_{\bullet j}}{N} \text{ für } i = 1, \ldots, r$$

bedingte Häufigkeitsverteilungen:

$$P(X_i|Y_j) = \frac{f_{ij}}{f_{\bullet j}} = \frac{p_{ij}}{p_{\bullet j}}$$

$$P(X_i|Y_j) = \frac{f_{ij}}{f_{i\bullet}} = \frac{p_{ij}}{p_{i\bullet}}$$

Statistische Unabhängigkeit der beiden Merkmale liegt vor, wenn gilt:

$$p_{ij} = p_{i\bullet} \cdot p_{\bullet j} \text{ für alle } i,\ j$$

1. Allgemeine Tabelle mit zwei Merkmalen X und Y

$X \backslash Y$	Y_1	Y_2	$\ldots$	Y_c	$\sum$
X_1	f_{11}	f_{12}	$\ldots$	f_{1c}	$f_{1\bullet}$
X_2	f_{21}	f_{22}	$\ldots$	f_{2c}	$f_{2\bullet}$
$\ldots$	$\ldots$	$\ldots$	$\ldots$	$\ldots$	$\ldots$
X_r	f_{r1}	f_{r2}	$\ldots$	f_{rc}	$f_{r\bullet}$
$\sum$	$f_{\bullet 1}$	$f_{\bullet 2}$	$\ldots$	$f_{\bullet c}$	N

2. Beispiel: Studierende nach Studienfach (Merkmal X) und Geschlecht (Merkmal Y)

$X \backslash Y$	weiblich	männlich	$\sum$
WI	700	300	1.000
BWL	1.400	1.600	3.000
Technik	1.500	500	2.000
$\sum$	3.600	2.400	6.000

3. Zweidimensionale Häufigkeitsverteilung mit relativen Häufigkeiten und Randverteilungen

$X \backslash Y$	weiblich	männlich	RV von $X(p_{ij})$
WI	0,117	0,050	0,167
BWL	0,233	0,267	0,500
Technik	0,250	0,083	0,333
RV von $Y(p_{\bullet j})$	0,600	0,400	1

Ob eine ökonomische Größe als „groß“ oder „klein“ anzusehen ist, lässt sich häufig nur dadurch erkennen, wenn man sie in Bezug zu anderen Größen setzt. Das Ergebnis sind **Verhältniszahlen:**
Beispiele:
Bruttoinlandsprodukt durch Einwohnerzahl Staatsschulden durch Bruttoinlandsprodukt Eine besondere Form von Verhältniszahlen sind **Indexzahlen**. Besonders wichtig sind **Preisindizes**. Im folgenden sei q_{ti} Menge des konsumierten Produkts i zum Zeitpunkt t und p_{ti} Preis des konsumierten Produkts i zum Zeitpunkt t. Hierbei bezieht sich q_{0i} und q_{0i} auf den Basiswarenkorb.
Preisindex nach Laspeyres:

$$P_{0t}^{L} = \frac{\sum_{i=1}^{m} p_{ti} \cdot q_{0i}}{\sum_{i=1}^{m} p_{0i} \cdot q_{0i}} \cdot 100$$

Preisindex nach Paasche:

$$P_{0t}^{P} = \frac{\sum_{i=1}^{m} p_{ti} \cdot q_{ti}}{\sum_{i=1}^{m} p_{0i} \cdot q_{ti}} \cdot 100$$

Beispielwarenkorb zur Inflationsberechnung:

Gut	Preise		Mengen	
	in t_0	in t_1	in t_0	in t_1
A	4	6	5	4
B	6	8	10	15
C	10	12	8	16

3.2 Korrelations- und Regressionsanalyse

Bei vielen Fragestellungen interessiert die **Stärke des Zusammenhangs** zwischen den untersuchten Merkmalen. Bevor man anfängt zu rechnen, sollte man sich hierbei aber Überlegen, ob die (Wirtschafts)theorie einen Zusammenhang zwischen den untersuchten Merkmalen nahe legt. Je nach Skalierung der Merkmale können unterschiedliche **Korrelationskoeffizienten** berechnet werden. Dies ist bei nominal skalierten Merkmalen vor allem der **PhiKoeffizient** und bei ordinal skalierten Merkmalen vor allem der **Rangkorrelationskoeffizient** nach Spearman. Die größte Bedeutung in der Praxis haben kardinal skalierte Merkmale. Hier berechnet man den **empirischen Korrelationskoeffizient** nach Bravais-Pearson.
empirischer Korrelationskoeffizient für kardinal skalierte Merkmale:

$$\rho = \frac{\sum_{i=1}^{N}(x_i - \overline{X}) \cdot (y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{N}(x_i - \overline{X})^2 \cdot (y_i - \overline{Y})^2}}$$

Während die Korrelationsanalyse nur die Stärke des Zusammenhangs untersucht, berücksichtigt die **Regressionsanalyse** zusätzlich die **funktionale Abhängigkeit** zwischen zwei (oder mehr) Größen; d.h. einseitige Einflussnahme von x auf y. So hat bspw. die Sonnenscheindauer einen Einfluss auf den Ernteertrag, nicht aber umgekehrt.
Bei der **linearen Einfachregression** wird folgende Regressionsgerade $\hat{y}$ zur Annäherung des Wertes y in Abhängigkeit von x ermittelt:

$$\hat{y}_i = \beta_0 + \beta_1 \cdot x_i$$

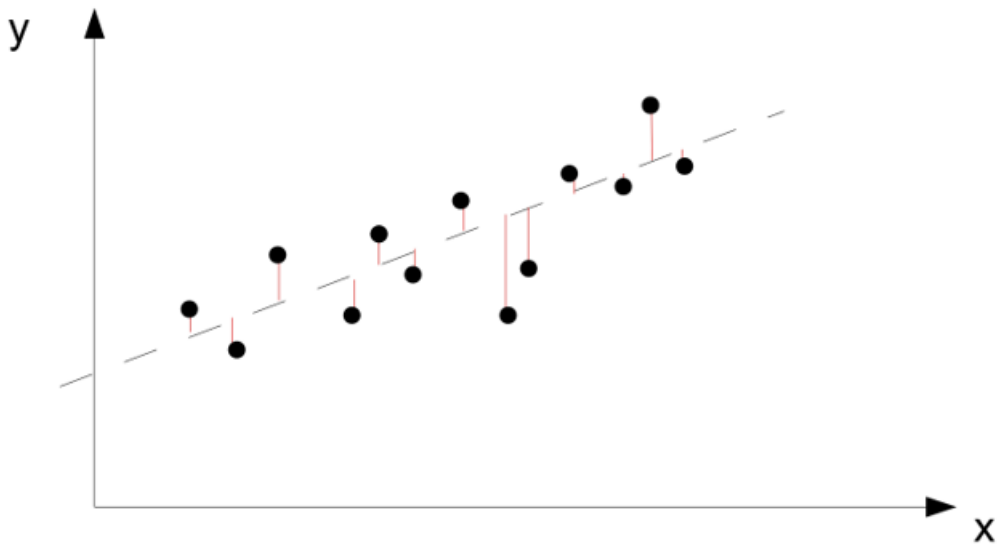

Das gebräuchlichste Verfahren zur Berechnung dieser Regressionsgerade durch minimieren der Fehler ϵ_i ist die **Methode der kleinsten Quadrate:**

$$\sum_{i=1}^{N} \epsilon_i^2 = \sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}(y_i - \beta_0 - \beta_i \cdot x_i)^2 \text{ minimieren!}$$

$$\beta_1 = \frac{\sum_{i=1}^{N}(x_i - \overline{X}) \cdot (y_i - \overline{Y})}{\sum_{i=1}^{N}(x_i - \overline{X})^2}$$
$$\beta_0 = \overline{Y} - \beta_1 \overline{X}$$

Um die Qualität einer Regressionsanalyse abzuschätzen, berechnet man den **Determinationskoeffizienten:**

$$R^2 = \frac{\beta_1^2 \sum_{i=1}^{N}(x_i - \overline{X})^2}{\sum_{i=1}^{N}(y_i - \overline{Y})^2}$$

Ein niedriger Determinationskoeffizient muss nicht in jedem Fall bedeuten, dass es zwischen den untersuchten Merkmalen keinen funktionalen Zusammenhang gibt. Möglicherweise ist dieser Zusammenhang aber **nichtlinear** oder wird von **anderen Variablen Überlagert**.

3.3 Zeitreihenanalyse

Bei der Zeitreihenanalyse wird untersucht, wie sich ein bestimmtes Merkmal im **Zeitablauf** entwickelt. Eine langfristige ökonomische Zeitreihe besitzt mit Trend, zyklischer Komponente, Saisonkomponente und Zufallskomponente bis zu **vier Komponenten**. Um die Zeitreihe zu glätten betrachtet man die Beobachtung selbst, sowie k Vorgänger und k Nachfolger. Dies ist die Methode der **gleitenden Durchschnitte**:
für ungeraden gleitenden Durchschnitt:

$$\overline{Y}_t^* = \frac{1}{2k+1} \cdot (y_{t-k} + y_{t-k+1} + \ldots + y_t + \ldots + y_{t+k-1} + y_{t+k})$$

z. B. 5er-Durchschnitt mit $k = 2$
für geraden gleitenden Durchschnitt:

$$\overline{Y}_t^* = \frac{1}{2k} \cdot (\frac{1}{2}y_{t-k} + y_{t-k+1} + \ldots + y_t + \ldots + y_{t+k-1} + \frac{1}{2}y_{t+k})$$

z. B. 4er-Durchschnitt mit $k = 2$
Bei vielen ökonomischen Fragestellungen ergibt sich der zu bildende Durchschnitt aus Plausibilitätsüberlegungen in Abhängigkeit von der **Frequenz der Werte** (z. B. bei Quartalsdaten 4er-Durchschnitt). Je größer der Durchschnitt gewählt wird, desto stärker wird die Zeitreihe geglättet. Allerdings gehen bei großen gleitenden Durchschnitten viele Werte „verloren“.
Wichtige **Trendverläufe** von Zeitreihen:

1. linearer Trend
2. Exponentialtrend
3. logistischer Trend

Liegt ein **linearer Trend** vor, so können die Überlegungen zur linearen Einfachregression nach der **Methode der kleinsten Quadrate** auf die Trendgerade angewendet werden:

$$\hat{y}_t = a + b \cdot t.$$

Eine Rechenvereinfachung erhält man, indem man den Zeitindex t'_t so wählt, dass er bei **Äquidistanten Zeitreihen** in der Summe 0 ergibt. Durchläuft also unsere Zeitreihe die Zeitschritte

t von $1 \dots T$, so können wir diese symmetrisch um den Nullpunkt verschieben. Beispielweise ergibt sich für $T = 9$ eine Verteilung von t'_t von $-4, -3, \dots, 3, 4$.
Es gilt dann:

$$\hat{y}_{t'} = a' + b \cdot t'$$

mit

$$a' = \frac{\sum_{t=1}^{T} y_t}{T} = \overline{Y}$$

$$b = \frac{\sum_{t=1}^{T} y_t \cdot t'_t}{\sum_{t=1}^{T} (t'_t)^2}$$

$$R^2 = \frac{b^2 \cdot \sum_{t=1}^{T} (t'_t)^2}{\sum_{t=1}^{T} (y_t - \overline{Y})^2}.$$

Kapitel 4

Wahrscheinlichkeitsrechnung

4.1 Ereignisse, Wahrscheinlichkeitsbegriffe, Axiome und Theoreme

Die Wahrscheinlichkeitsrechnung stellt die Basis für die induktive Statistik dar, weil beim Schließen von einer Stichprobe auf die Grundgesamtheit wahrscheinlichkeitstheoretische Überlegungen benötigt werden.
Die Wahrscheinlichkeitsrechnung beschäftigt sich mit **zufälligen Ereignissen**. Dies sind Vorgänge, deren Ergebnis nicht mit Sicherheit vorausgesagt werden kann.
Beispiele: Münzwurf, Würfel, Urnenmodell, Roulette
Grundbegriffe:
Die **Vereinigung** zweier Ereignisse A und B, nämlich das neue Ereignis $A \cup B$, ist als die Menge aller Elementarereignisse, die zu A oder B gehören, definiert.
Der **Durchschnitt** zweier Ereignisse A und B, nämlich das neue Ereignis $A \cap B$, ist als die Menge aller Elementarereignisse, die zu A und B gehören, definiert.
Zwei Ereignisse A und B schließen einander aus, d.h. sie sind **disjunkt (= unvereinbar)**, wenn es kein Elementarereignis gibt, das zu beiden gleichzeitig gehört.
Ein Ereignis B ist dann von einem Ereignis A **unabhängig**, wenn das Eintreten von B nicht von dem Eintreten oder Nichteintreten von A abhängt.
Wahrscheinlichkeitsbegriffe:
Der **klassische Wahrscheinlichkeitsbegriff** nach Laplace ist nur dann anwendbar, wenn alle Elementarereignisse die gleiche Wahrscheinlichkeit haben. Man berechnet den Quotient aus der Zahl der günstigen Fälle zur Zahl aller gleichmöglichen Fälle.
Der **statistische Wahrscheinlichkeitsbegriff** geht von einem Zufallsexperiment aus, das aus einer langen Folge voneinander unabhängiger Versuche besteht. Das häufige Wiederholen eines Experiments ermöglicht Aussagen zur Wahrscheinlichkeit.
Der **subjektive Wahrscheinlichkeitsbegriff** spielt bei vielen Fragestellungen in der ökonomie eine wichtige Rolle. Er stellt den (mehr oder weniger fundierten) persönlichen überzeugungsgrad dar.
Aus den **Axiomen** (= Grundsätze formaler Art, die keines Beweises bedürfen), lassen sich verschiedene **Theoreme der Wahrscheinlichkeitsrechnung** herleiten:
Addition paarweise disjunkter (= unvereinbarer) Ereignisse:

$$P(A_1 \cup A_2 \cup \ldots \cup A_n) = P(A_1) + P(A_2) + \ldots + P(A_n)$$

Addition zweier beliebiger Ereignisse:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

bedingte Wahrscheinlichkeit:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

bzw. bei Unabhängigkeit mit $P(A \cap B) = P(A) \cdot P(B)$ gilt

$$P(A \mid B) = P(A)$$

Produkt von n Ereignissen:

$$P(A_1 \cap A_2 \cap \ldots \cap A_n) = P(A_1) \cdot P(A_2 \mid A_1) \cdot P(A_3 \mid A_1 \cap A_2) \cdot \ldots \cdot P(A_n \mid A_1 \cap \ldots \cap A_{n-1})$$

Theorem für die totale Wahrscheinlichkeit (bei n paarweise disjunkten Ereignissen $A_i,\ i = 1, \ldots, N$):

$$\begin{aligned} P(B) &= P(A_1) \cdot P(B \mid A_1) + P(A_2) \cdot P(B \mid A_2) + \ldots + P(A_n) \cdot P(B \mid A_n) \\ &= \sum_{j=1}^{n} P(A_j) \cdot P(B \mid A_j) \end{aligned}$$

Bayes-Theorem:
Für zwei Ereignisse A und B mit $P(B) > 0$ lässt sich die Wahrscheinlichkeit von A unter der Bedingung, dass B eingetreten ist, durch die Wahrscheinlichkeit von B unter der Bedingung, dass A eingetreten ist, errechnen:

$$P(A \mid B) = \frac{P(B \mid A) \cdot P(A)}{P(B)}.$$

Verallgemeinert gilt, wenn $A_i,\ i = 1, \ldots, N$ eine Zerlegung der Ergebnismenge in disjunkte Ereignisse ist

$$\begin{aligned} P(A_i \mid B) &= \frac{P(A_i) \cdot P(B \mid A_i)}{P(A_1) \cdot P(B \mid A_1) + P(A_2) \cdot P(B \mid A_2) + \ldots + P(A_n) \cdot P(B \mid A_n)} \\ &= \frac{P(A_i) \cdot P(B \mid A_i)}{\sum_{j=1}^{n} P(A_j) \cdot P(B \mid A_j)} \end{aligned}$$

4.2 Kombinatorik

Die Kombinatorik behandelt die Fragestellung, wie viele Möglichkeiten es gibt verschiedene Elemente zu ordnen bzw. zusammenzustellen.
Sollen **n Elemente nebeneinander gereiht** werden, spricht man von einer **Permutation:**

$$P_n = n!$$

Sollen dagegen **aus n Elementen Zusammenstellungen k-ter Ordnung** gebildet werden, hängt die Zahl der Möglichkeiten davon ab, ob man die Anordnung berücksichtigt und ob man Wiederholungen zulässt.

Variation (mit Berücksichtigung der Anordnung):
ohne Wiederholung:

$$V_n^{(k)} = \frac{n!}{(n-k)!}$$

mit Wiederholung:

$$V_n^{(k)} = n^k$$

Kombination (ohne Berücksichtigung der Anordnung):
ohne Wiederholung:

$$C_n^{(k)} = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

mit Wiederholung:

$$C_n^{(k)} = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$$

4.3 Zufallsvariablen und ihre Verteilung

Eine **Zufallsvariable** X ist eine Größe, die den möglichen Ergebnissen eines Zufallsvorgangs reelle Zahlen zuordnet.
Wahrscheinlichkeitsfunktion einer diskreten Zufallsvariable:

$$f(x_i) = P(X = x_i) = p_i$$

Verteilungsfunktion einer diskreten Zufallsvariable:

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i)$$

Erwartungswert einer diskreten Zufallsvariable:

$$E(x) = \mu = \sum_{i=1}^{n} x_i \cdot f(x_i) = \sum_{i=1}^{n} x_i \cdot p_i$$

Varianz einer diskreten Zufallsvariable:

$$Var(X) = \sigma^2 = \sum_{i=1}^{n} (x_i - \mu)^2 \cdot f(x_i) = \sum_{i=1}^{n} {x_i}^2 \cdot f(x_i) - \mu^2$$

Die **Standardabweichung** σ ist die Wurzel der Varianz.

Wir kÃ¶nnen neben diskreten auch stetige Zufallsvariable betrachten. Hierbei verwendet man Wahrscheinlichkeitsdichte/Dichtefunktionen $f(x)$. Für diese Funktionen muss gelten:

$$f(x) \geq 0 \text{für alle Zufallsvariablen} x$$

$$\int_{-\infty}^{\infty} f(t)dt = 1$$

Wahrscheinlichkeitsdichte/Dichtefunktion einer stetigen Zufallsvariable:

$$P(a \leq X \leq b) = \int_a^b f(t)dt$$

insbesondere gilt:

$$P(X = a) = 0$$
$$P(a \leq X \leq b) = P(X \leq b) - P(x < a) = P(X \leq b) - P(x \leq a)$$
$$P(X > a) = 1 - P(x \leq a)$$

Verteilungsfunktion einer stetigen Zufallsvariable:

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt$$

Erwartungswert einer stetigen Zufallsvariable:

$$E(X) = \int_{-\infty}^{\infty} t \cdot f(t)dt$$

Varianz einer stetigen Zufallsvariable:

$$Var(X) = \int_{-\infty}^{\infty} (t - E(X))^2 \cdot f(t)dt$$

4.4 Spezielle diskrete und stetige Wahrscheinlichkeitsverteilungen

In der Praxis kommen verschiedene **theoretische Wahrscheinlichkeitsverteilungen** zum Einsatz, welche die Berechnungen von Wahrscheinlichkeiten sowie verschiedener Maßzahlen erheblich erleichtern.
Bei den **diskreten Zufallsvariablen** stehen insbesondere die Binomialverteilung, die Hypergeometrische Verteilung und die Poissonverteilung im Mittelpunkt.
Bei den **stetigen Zufallsvariablen** sind vor allem die Normalverteilung bzw. Standard-Normalverteilung (Gaußsche Glockenkurve), die Rechteckverteilung und die Exponentialverteilung von Bedeutung.

4.4.1 Diskrete Zufallsvariablen

Die **Binomialverteilung** setzt voraus, dass ein Zufallsvorgang n-mal wiederholt wird. Die einzelnen Vorgänge sind voneinander **unabhängig** („Urne mit Zurücklegen“). Es gibt nur zwei mögliche Ergebnisse und bei allen Versuchen jeweils die gleiche Erfolgswahrscheinlichkeit p bzw. Misserfolgswahrscheinlichkeit $q = 1 - p$. Die Wahrscheinlickeit $P(X = k)$ für k erfolge ist dann:

$$P(X = k) = \binom{n}{k} p^k \cdot q^{n-k}$$
$$E(X) = n \cdot p$$
$$Var(X) = n \cdot p \cdot q$$

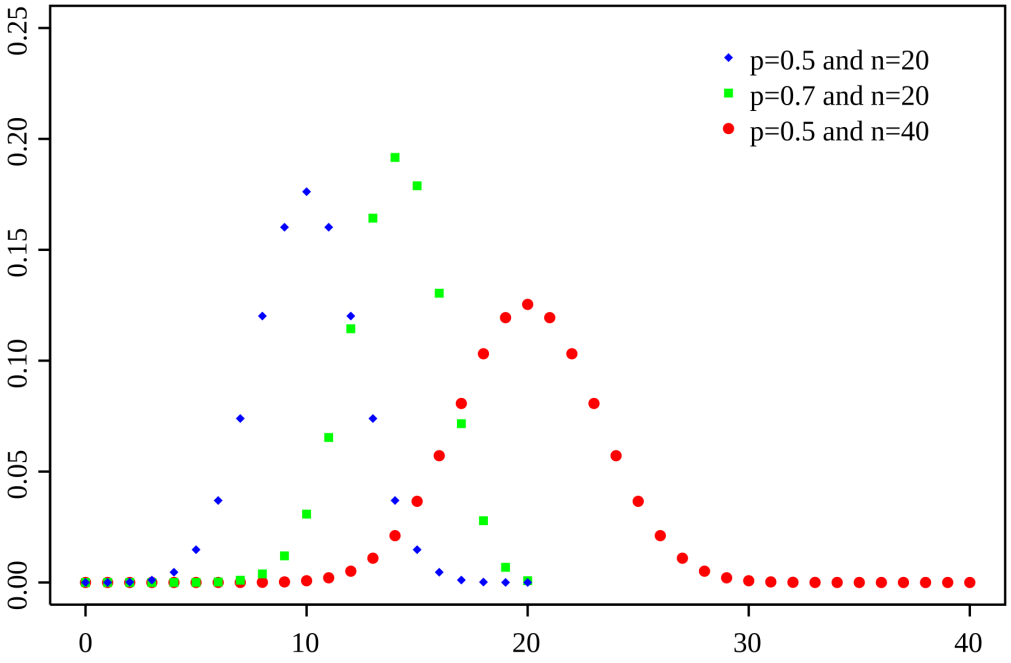

Im Unterschied dazu wird bei der **Hypergeometrischen Verteilung** das „Urnenmodell ohne Zurücklegen“ betrachtet. Es liegt also **keine Unabhängigkeit** der einzelnen Zufallsvorgänge vor. In der Anzahl der Grundgesamtheit N gibt es $M \leq N$ Elemente mit einer bestimmten Eigenschaft (beispielweise die Anzahl möglicher Erfolge). Insgesamt kommen $n \leq N$ der Elemente in einer Stichprobe. Die Wahrscheinlichkeit $P(X = k)$ insgesamt k Elemente mt der bestimmten Eigenschaft in der Stichprobe zu haben ist:

$$P(X = k) = \frac{\binom{M}{k} \cdot \binom{N-M}{n-k}}{\binom{N}{n}}$$

$$E(X) = n \cdot \frac{M}{N}$$

$$Var(X) = n \cdot \frac{M}{N} \cdot \frac{N-M}{N} \cdot \frac{N-n}{N-1}$$

Beträgt der Stichprobenumfang n maximal 5% im Verhältnis zur Zahl der Elemente in der Grundgesamtheit N, so kann die **Hypergeometrische Verteilung durch die Binomialverteilung approximiert** werden.
Diese Approximation spielt in der Praxis insbesondere bei der **Qualitätskontrolle** eine wichtige Rolle.
Die **Poissonverteilung** wird auch als Verteilung der **seltenen Ereignisse** bezeichnet. Sie kommt bei einem sehr großen Stichprobenumfang n und sehr kleinen Wahrscheinlichkeiten p zum Einsatz. Als Faustregel (nicht einheitlich in der Literatur) gilt, dass für $n \geq 50$ und $p \leq 0,1$ die Binomialverteilung (und bei Vorliegen bestimmter Voraussetzungen auch die Hypergeometrische Verteilung) durch die Poissonverteilung approximiert werden können.
Die wichtigsten Werte für Poissonverteilung und Binomialverteilung liegen im Gegensatz zur Hypergeometrischen Verteilung **tabelliert** vor.

$$n \cdot p = \lambda$$
$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$
$$E(X) = n \cdot p = \lambda$$
$$Var(X) = n \cdot p = \lambda$$

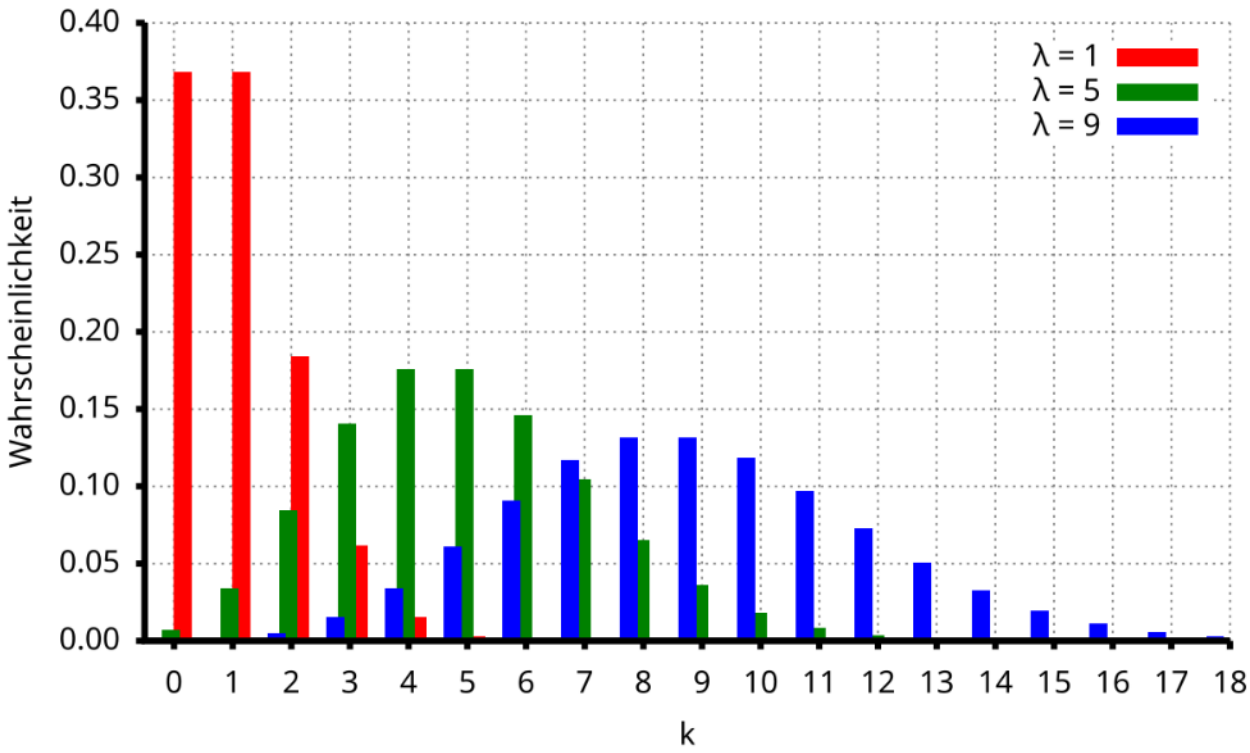

4.4.2 Stetige Zufallsvariablen

Die **Normalverteilung oder Gaußverteilung** ist die am **meisten verwendete Verteilung**. Sie hat ihr Maximum bei μ, ist symmetrisch bzgl. μ, hat ihre Wendepunkte bei $\mu \pm \sigma$ und nähert sich asymptotisch der x-Achse an. Sie wird aus folgenden Gründen häufig verwendet:

- viele Zufallsvariablen sind normalverteilt
- oft Approximation durch Normalverteilung möglich

Zentraler Grenzwertsatz: Der Mittelwert $\overline{X}$ von unabhängigen,identisch verteilten Zufallsvariable ist normalverteilt, wenn $n \to \infty$. Konkret bedeutet Dies für $X_1; X_2; \ldots; X_n$ stochastisch unabhängige Zufallsvariablen, deren Verteilungsfunktionen alle gleich sind mit gleichen Erwartungswerten $E(X_i) = \mu$ und gleichen Varianzen $Var(X_i) = \sigma^2$ das die Zufallsvariable

$$Z = \frac{(X_1 + X_2 + \ldots + X_n) - n\mu}{\sqrt{n}\sigma}$$

für $n \to \infty$ standard-normalverteilt.
Jede Normalverteilung kann nach diesem Satz durch eine spezielle Transformation standardisiert werden (= **Standard-Normalverteilung**). Die Werte der dazugehörigen Verteilungsfunktion sind **tabelliert**. Der Erwartungswert ist nun 0, die Varianz und somit auch die Standardabweichung 1.

$$Z = \frac{X - \mu}{\sigma} \text{ Standardisierung}$$

Die Dichtefunktion einer solchen Standard-Normalverteilung ist:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$

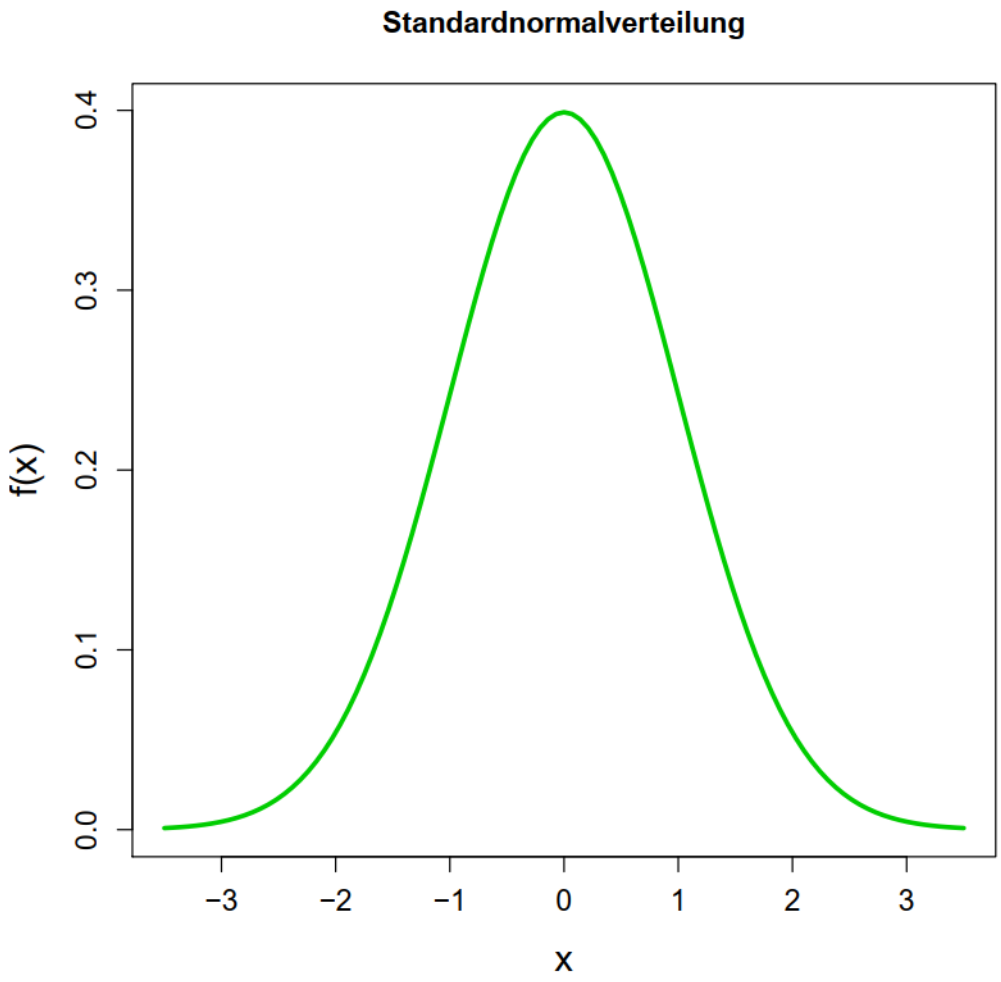

Die **Rechteckverteilung** wird auch als **stetige Gleichverteilung** bezeichnet. In einem bestimmten **Intervall von a bis b** ist die Wahrscheinlichkeitsdichte konstant.

$$P(x \leq X \leq x + \Delta x) = \frac{1}{a - b} \cdot \Delta x$$

$$E(X) = \frac{a + b}{2}$$

$$Var(X) = \frac{(a-b)^2}{12}$$

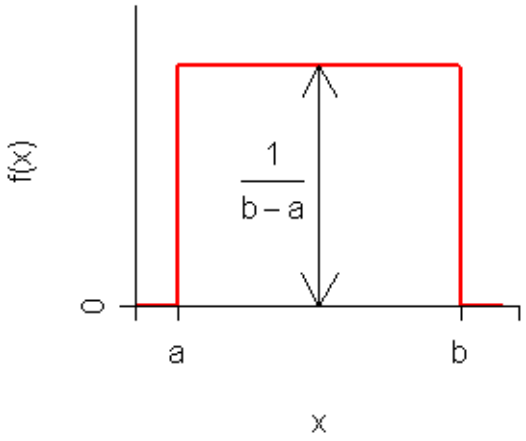

Bei der **Exponentialverteilung** misst die Zufallsvariable X die **Zeit bis zum Eintreffen eines Ereignisses**. Dabei wird vorausgesetzt, dass die Wahrscheinlichkeit für das Eintreffen des Ereignisses in jedem Zeitpunkt gleich hoch ist.
Beispiel: Ein PC stürzt im Durchschnitt alle 5 Stunden ab und muss neu gestartet werden. Die Wahrscheinlichkeit des Abstürzens ist in jedem Moment gleich hoch.
Die Dichtefunktionfunktion ist:

$$f(x) = \lambda \cdot e^{-\lambda x}$$

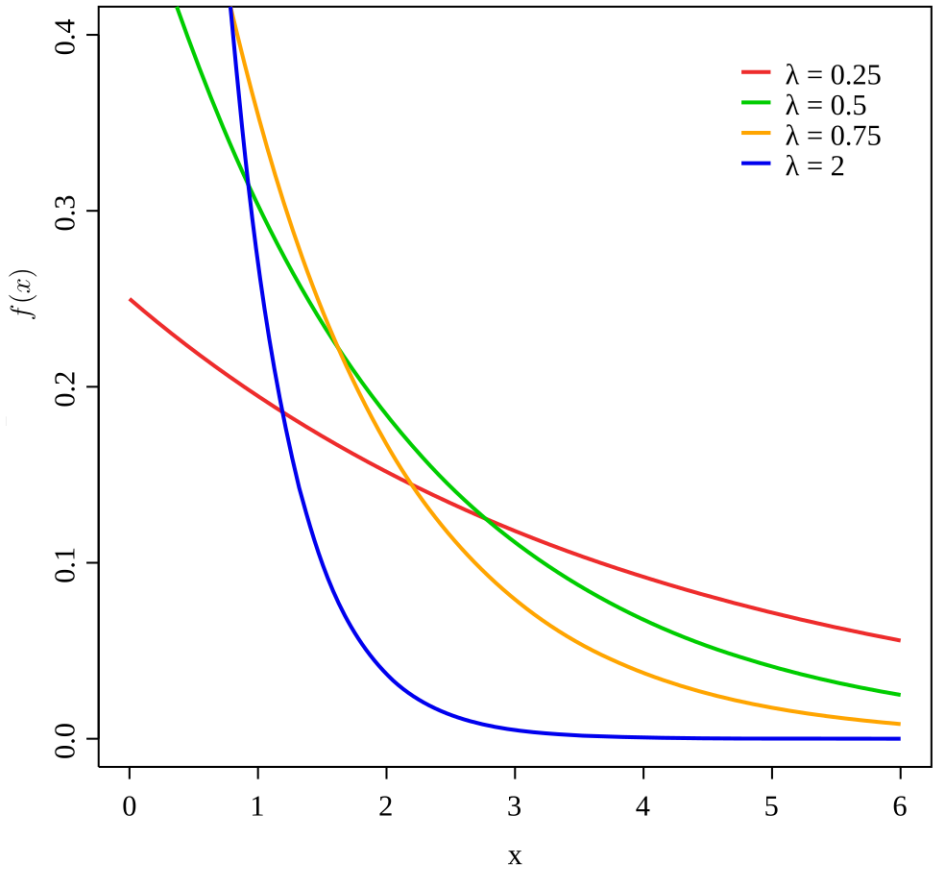

Die Kumulierte Wahrscheinlichkeit, das der PC bis zu einem Zeitpunkt x abgestürzt ist, entsprechend:

$$P(X \leq x) = \int_0^x f(t)dt = 1 - e^{-\lambda x}$$

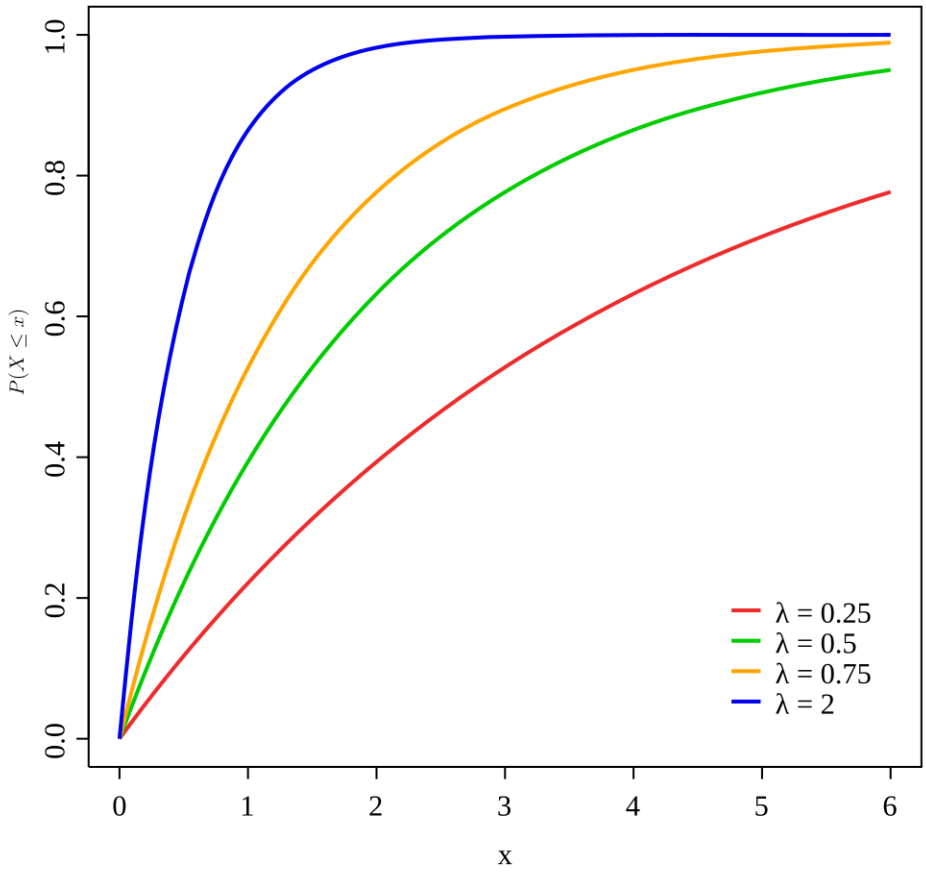

Mit der Exponentialverteilung kann nun z. B. berechnet werden, mit welcher Wahrscheinlichkeit man mehr als drei Stunden ununterbrochen an dem PC arbeiten kann.

$$P(X > x) = 1 - P(X \leq x) = 1 - (1 - e^{-\lambda x}) = e^{-\lambda x}$$

$$E(X) = \frac{1}{\lambda}$$

$$Var(X) = \frac{1}{\lambda^2}$$

Kapitel 5

Induktive Statistik

5.1 Stichprobentheorie

Bei sehr vielen statistischen Erhebungen wird nicht auf eine **Vollerhebung**, sondern nur auf eine **Teilerhebung (= Stichprobe)** zurückgegriffen. Beim Ziehen einer Stichprobe ist darauf zu achten, dass die Stichprobe **repräsentativ** für die Grundgesamtheit ist.
Gründe für das Ziehen von Stichproben sind vor allem **Kostenersparnis** und **Zeitgewinn**. In vielen Fällen ist es aber auch praktisch unmöglich eine Vollerhebung durchzuführen. Man unterscheidet beim Ziehen einer Stichprobe zwischen **verschiedenen Verfahren**:

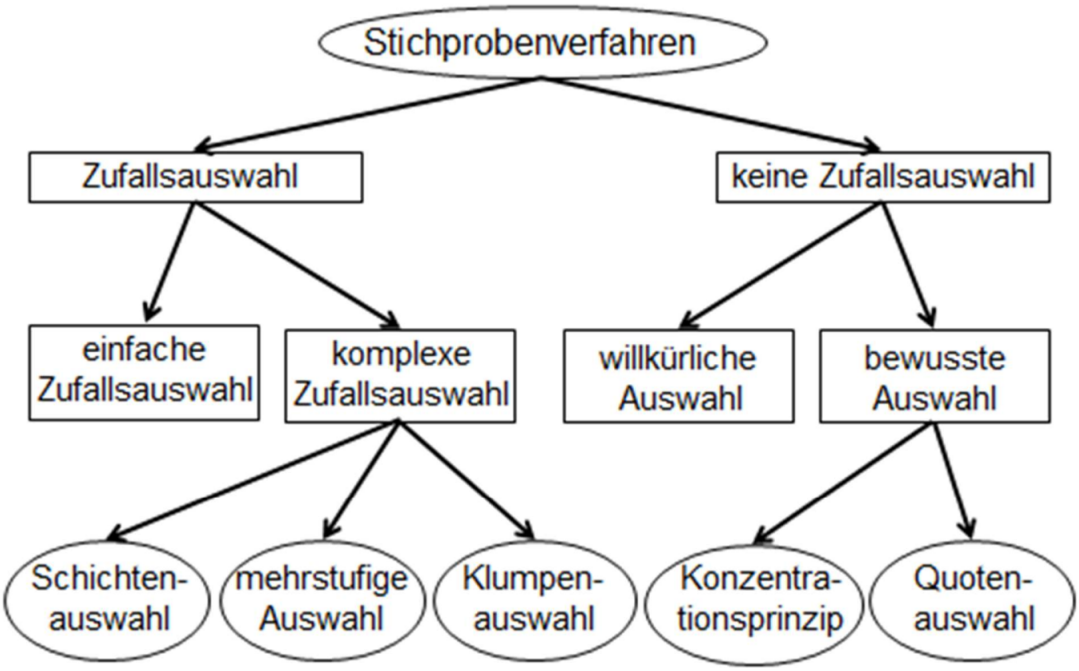

Nur bei den **Zufallsauswahlverfahren** ist das statistische Instrumentarium (insbesondere wahrscheinlichkeitstheoretische Aussagen) der **induktiven Statistik** komplett anwendbar.
Bei einer **einfachen (= reinen) Zufallsauswahl** werden auf Basis einer durchnummerierten Liste einzelne Merkmalsträger durch Auslosen bzw. über das Verwenden von Zufallszahlengeneratoren **zufällig** ausgewählt.

Schichtenauswahl: Bildung homogener Schichten und dann dort jeweils Zufallsauswahl
Klumpenauswahl: Bildung und Zufallsauswahl von Klumpen, die ein verkleinertes Abbild der Grundgesamtheit darstellen, dort Befragung aller; wenn in Klumpen weitere Zufallsauswahl (= **mehrstufige Auswahl**)
Besonders in der **Markt- und Meinungsforschung** wird oft mit der **Quotenauswahl** ein Verfahren der bewussten Auswahl verwendet. Es wird ein Quotenplan (gemäß Merkmalen der Grundgesamtheit) vorgegeben. Die eigentliche Auswahl der zu Befragenden ist dann aber frei.
In der **amtlichen Statistik** spielt zudem aus Praktikabilitätsgründen die **Auswahl nach dem Konzentrationsprinzip (= Abschneideverfahren)** eine wichtige Rolle.
Verfahren der bewussten Auswahl sind im Unterschied zu den Zufallsauswahlverfahren **einfacher anwendbar.** Unter bestimmten Voraussetzungen können auch hier weitgehend repräsentative Stichprobenergebnisse erzielt werden.

5.2 Punkt- und Intervallschätzung

Liegt eine Stichprobenerhebung vor, so soll auf Basis der Ergebnisse der Stichprobe auf die **unbekannten Parameter der Grundgesamtheit** geschlossen werden. In vielen Fällen wird dabei eine „medienwirksame“ **Punktschätzung** (Übertragung des entsprechenden Parameters der Stichprobe auf die Grundgesamtheit) durchgeführt. Unter statistischen Gesichtspunkten ist eine solche Punktschätzung aber relativ problematisch. Seriöser, aber im Medienzeitalter schwerer vermittelbar, sind **Intervallschätzungen**. Hierbei wird ausgehend von dem Ergebnis der Stichprobe ein **Konfidenzintervall** angegeben, in dem der zu schätzende Parameter der Grundgesamtheit mit einer bestimmten vorgegebenen **Wahrscheinlichkeit** liegt. Konfidenzintervalle können für verschiedene Parameter (arithmetisches Mittel, Anteilswert, Varianz) und unterschiedliche Verteilungen bestimmt werden. Ihre Breite hängt ab von:

- Umfang der Stichprobe
- Streuung des untersuchten Merkmals
- vorgegebene Wahrscheinlichkeit

Beispielhaft betrachtet sei das **Konfidenzintervall für das arithmetische Mittel**, also das Intervall das mit einer vorgegebenen Wahrscheinlichkeit $1-\alpha$ den wahren Parameter enthält. (Annahmen: Normalverteilung und σ bekannt bzw. Stichprobenumfang $n > 30$):

$$P\left(\overline{X} - z \cdot \frac{\sigma}{\sqrt{n}} \leq \mu \leq \overline{X} + z \cdot \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

hierbei ist

$$z = \frac{\overline{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

Ist σ nicht bekannt so wird es aus der bekannten Stichprobe berechnet, die so gewonnene Schätzung wird mit s bezeichnet. Dann berechnet sich das Konfidenzintervall mit:

$$P\left(\overline{X} - t \cdot \frac{s}{\sqrt{n}} \leq \mu \leq \overline{X} + t \cdot \frac{s}{\sqrt{n}}\right) = 1 - \alpha$$

hierbei ist

$$t = \frac{\overline{X} - \mu_0}{\frac{s}{\sqrt{n}}}$$

5.3 Testverfahren

Auf Basis der Ergebnisse einer Stichprobe soll überprüft werden, ob bestimmte **Hypothesen** über die unbekannte Grundgesamtheit richtig oder falsch sind. Hierbei kommen **Testverfahren** zum Einsatz. Man unterscheidet dabei zwischen **Parametertests** und **Verteilungstests**. Bei solch einem Test (z.B. im Rahmen der Qualitätskontrolle) wird eine **Nullhypothese** H_0 und eine **Alternativhypothese** H_1 aufgestellt. Je nach Fragestellung ist ein **einseitiger oder zweiseitiger Test** sinnvoll. **Null- und Alternativhypothese bei Testverfahren:**

Entscheidung aufgrund der Stichprobe	wahrer Zustand	
	H_0 trifft zu	H_0 trifft nicht zu→H_1
H_0 wird nicht abgelehnt (= wird akzeptiert)	richtige Entscheidung	β-Fehler (Fehler 2. Art)
H_0 wird abgelehnt	α-Fehler (Fehler 1. Art)	richtige Entscheidung

Ziel des Statistikers ist es, das Testverfahren so zu konzipieren, dass die Wahrscheinlichkeit für den α**-Fehler** und auch für den β**-Fehler** in vertretbaren Grenzen gehalten wird. Die Vorgehensweise bei Tests ist wie folgt:

1. Formulierung von Nullhypothese H_0 und Alternativhypothese H_1. Vergleich des Erwartungswertes μ der Stichprobe und dem Erwartungswert unter der Nullhypothese μ_0.

$$\begin{aligned} \text{linksseitiger Test:} \quad & H_0 : \mu \geq \mu_0 \text{ und} \quad H_1 : \mu < \mu_0 \\ \text{rechtsseitiger Test:} \quad & H_0 : \mu \leq \mu_0 \text{ und} \quad H_1 : \mu > \mu_0 \\ \text{zweiseitiger Test:} \quad & H_0 : \mu = \mu_0 \text{ und} \quad H_1 : \mu \neq \mu_0 \end{aligned}$$

2. Festlegung der Irrtumswahrscheinlichkeit (1%, 5% oder 10%)

3. Festlegung einer geeigneten Prüfgröße (abhängig von Art des Tests)

4. Festlegung der Entscheidungsregel (wann wird H_0 abgelehnt)

5. Berechnung der Prüfgröße

6. Entscheidung und Interpretation (Vergleich berechneter Wert mit Entscheidungsregel)

Prüfgröße für das arithmetische Mittel: (Annahmen: Normalverteilung bzw. Stichprobenumfang $n > 30 \rightarrow z$-Verteilung, sonst t-Verteilung):

$$z = \frac{\overline{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

In vielen Statistikprogrammen wird bei Testverfahren die **Überschreitungswahrscheinlichkeit (= p-value)** berechnet. Das ist die Irrtumswahrscheinlichkeit, die man vorgeben müsste, wenn man die Nullhypothese gerade noch akzeptieren möchte (üblich 1%, 5% oder 10%).
Es gilt:

p-value $\leq 1\% \rightarrow$ Ablehnung der Nullhypothese

$1\% < p$-value $\leq 10\% \rightarrow$ Entscheidung abhängig vom gewählten α -Wert

p-value $> 10\% \rightarrow$ Nichtablehnung der Nullhypothese

Prüfgröße für den Anteilswert: In einer n Stichprobe hat ein unbekannter Anteil π von Elementen eine interessierende Eigenschaft. Über π existiert eine Annahme (hypothetischer Wert) π_0. Diese Annahme soll mittels eines statistischen Tests geprüft werden.
(Annahmen: $n \cdot \pi_0 \cdot (1 - \pi_0) \geq 9 \rightarrow$ Approximation über Normalverteilung und damit z-Verteilung möglich)

$$z = \frac{p - \pi_0}{\sigma_p}$$

mit

$$\sigma_p = \sqrt{\frac{\pi_0 \cdot (1 - \pi_0)}{n}}$$